PRÉSENTATION | 19 Novembre 2026

Modèles hybrides

« Quand modèle de connaissance et modèle d'apprentissage s'associent pour modéliser ce que ni la physique seule, ni les données seules ne peuvent capturer »

Systèmes réactifs complexes : apports, limites et perspectives des approches hybrides physique–IA

Roda Bounaceur – roda.bounaceur@univ-Lorraine.fr
Université de Lorraine, CNRS, LRGP, F-54000 Nancy, France



Photo : ©Vincent DAMARIN

Sommaire

01 **Concepts**

Description d'un modèle hybride • Forces et limites de chaque famille

02 **Couplage et architectures**

Comment relier MC et IA • Architectures possibles

03 **Avantages et inconvénients**

Avantages • Inconvénients

04 **Cas pratique**

Bioréacteur fed-batch • Haldane et Monod • IA pure • Hybride série • Données • Architectures • Limites • PINN

MC : modèle de connaissance
IA : modèle guidé par les données

LRGP
LABORATOIRE RÉACTIONS ET GÉNIE DES PROCÉDÉS

Concepts

De quoi parle t'on?

Il n'existe pas de nomenclature universelle et exhaustive : les appellations se recouvrent et leur sens varie selon les communautés. Le tableau suivant distingue les termes largement établis des désignations plus variables.

Hybrid modeling

Combiner une composante de connaissance et une composante apprise

Grey-box modeling

Exploiter une connaissance partielle de la structure du système

Semi-physical modeling

Conserver les relations fiables et apprendre les relations mal connues

SciML Scientific Machine Learning

Articuler calcul scientifique, modèles mathématiques et apprentissage

PIML Physics-Informed Machine Learning

Intégrer les lois ou contraintes physiques au ML

PGML Physics-Guided Machine Learning

Guider les données, les variables, la structure ou l'apprentissage par la physique

SGML Science-Guided Machine Learning

Intégrer plus largement des connaissances scientifiques au ML

Knowledge-based neural modeling

Introduire des relations connues dans la structure d'un modèle neuronal

De quoi parle t'on?

Tableau des principales familles techniques

Méthodes d'apprentissage automatique pour la physique

Acronyme	Développement	Fonction principale	Place de la connaissance
PINN	Physics-Informed Neural Network	Approximer une solution et/ou identifier des paramètres en pénalisant les écarts aux équations	Fonction de coût et parfois contraintes imposées
UDE	Universal Differential Equation	Compléter une équation différentielle par une fonction apprise	Structure des équations
Neural ODE / NODE	Neural Ordinary Differential Equation	Représenter tout ou partie du champ de dérivées par un réseau	Pas nécessairement physique ; dépend de la structure imposée
PINO	Physics-Informed Neural Operator	Apprendre un opérateur de solution avec des contraintes physiques	Apprentissage d'opérateur et résidus physiques
FNO	Fourier Neural Operator	Apprendre une correspondance entre fonctions à l'aide de couches spectrales	Pas physiquement contraint par défaut

Acronyme	Développement	Fonction principale	Place de la connaissance
DeepONet	Deep Operator Network	Apprendre un opérateur reliant une fonction d'entrée à une fonction de sortie	Pas physiquement contraint par défaut
SINDy	Sparse Identification of Nonlinear Dynamics	Identifier une dynamique parcimonieuse dans une bibliothèque de fonctions	Choix des variables et termes candidats
SINDYc	Sparse Identification of Nonlinear Dynamics with Control	Étendre l'identification parcimonieuse aux systèmes avec entrées/commande	Structure dynamique et termes de commande
HNN	Hamiltonian Neural Network	Apprendre une fonction hamiltonienne pour construire la dynamique	Structure hamiltonienne
LNN	Lagrangian Neural Network	Apprendre un lagrangien puis construire la dynamique associée	Structure lagrangienne

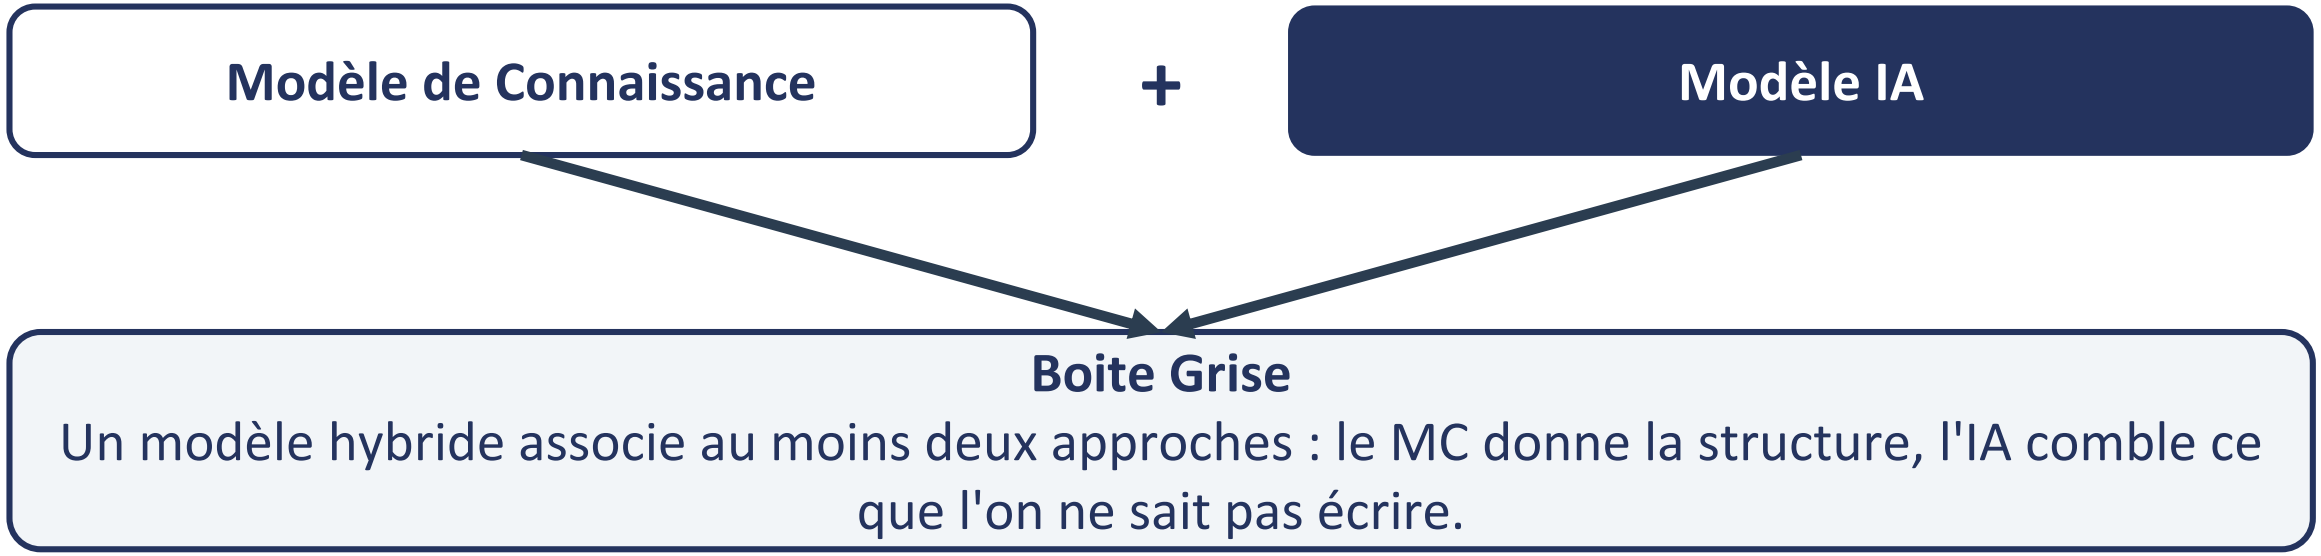
Plusieurs définitions possibles

Modèle de Connaissance	“+”	Modèle guidé par les données
Modèle déterministe	“+”	Apprentissage statistique
Boîte blanche	“+”	Boîte noire
Modèle physique	“+”	Modèle IA

“etc..”

Un modèle hybride associe au moins deux approches :
le MC donne la structure, l'IA comble ce que l'on ne sait pas écrire.

Terminologie et définition retenue



Définition retenue

Le MC fournit la structure : bilans, lois de conservation.

L'IA capte les paramètres ou les états incertains, difficiles à écrire explicitement.

Des forces complémentaires

MC

Points forts

- Interprétable
- Extrapole bien
- Sans données pour le construire

Point faible

- ➢ Mécanismes latents mal connus
- ➢ Expertise nécessaire

Hybride
structure du MC + souplesse de l'IA

IA

Points forts

- “Rapide à developer”
- Flexible
- Capte l'inconnu

Point faible

- ➢ Bruit, données rares
- ➢ Beaucoup de données nécessaires

LRGP
LABORATOIRE RÉACTIONS ET GÉNIE DES PROCÉDÉS

Couplage et architectures

Deux modes de couplage

Mode 1

Par un terme d'équation

L'IA fournit un paramètre ou un terme inconnu (vitesse de croissance, cinétique, coefficient de transfert), injecté dans les bilans.

$$dx/dt = f(x, u, p) \quad avec \quad p = IA(x, u)$$

Mode 2

Par l'écart aux mesures

L'IA estime la différence entre la prédiction du MC et l'expérience, puis la corrige.

$$y = y_MC + \varepsilon \quad avec \quad \varepsilon = IA(x, u)$$

Trois architectures de base

A

Série

IA → MC

L'IA alimente le MC

B

Série

MC → IA

Le MC alimente l'IA

C

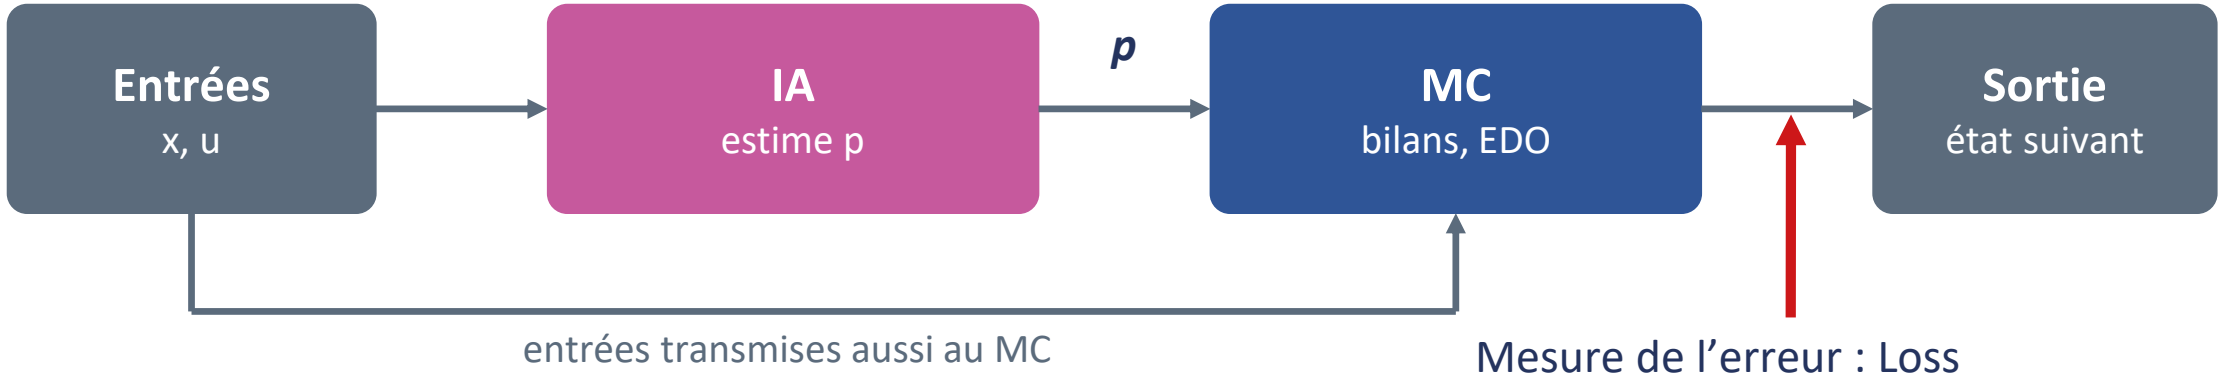
Parallèle

MC || IA

L'IA corrige le résidu

Enjeu : l'architecture des échanges entre MC et IA fixe la justesse et la robustesse de l'ensemble.

A · Série : l'IA alimente le MC



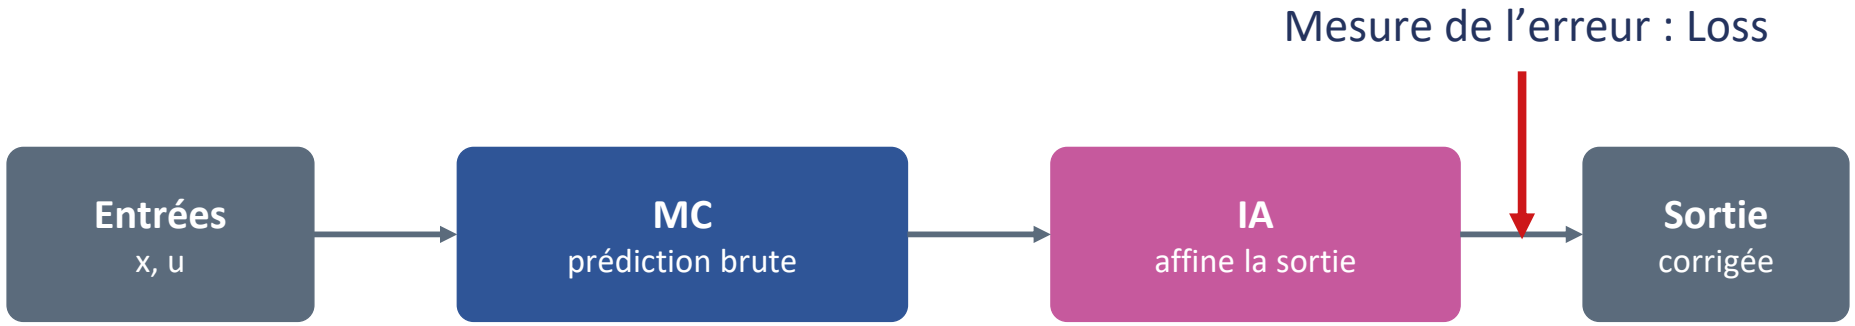
Atout

- Bilans conservés par construction.
- Les paramètres estimés gardent un sens physique.

Limite

Une valeur d'IA inappropriée dégrade directement le MC. La perte porte sur la sortie du modèle complet, car p n'est pas mesurable.

B · Série : le MC alimente l'IA



La sortie du MC est une variable explicite de l'architecture, utilisée comme entrée de l'IA.

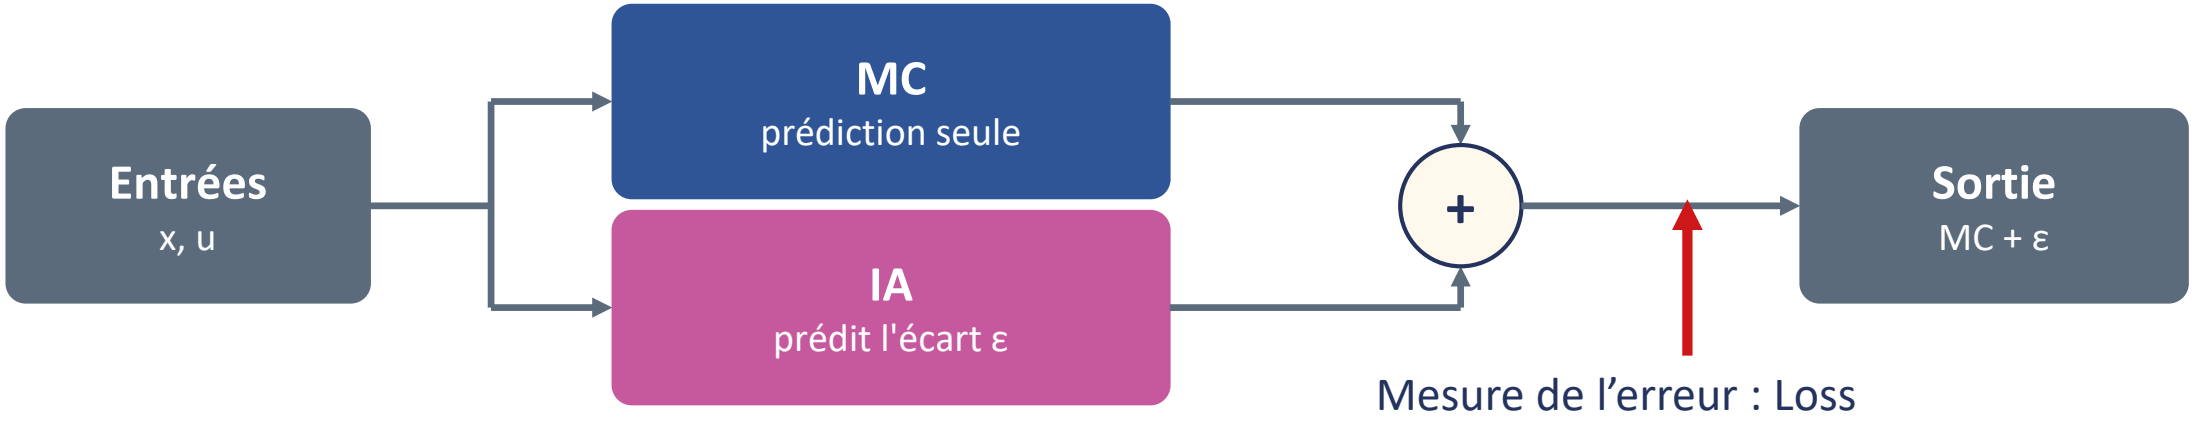
Atout

La sortie du MC reste une variable explicite et lisible dans la chaîne.

Limite

Les bilans ne sont pas garantis en sortie. Comportement hors domaine d'entraînement à surveiller.

C · Parallèle : l'IA corrige l'écart



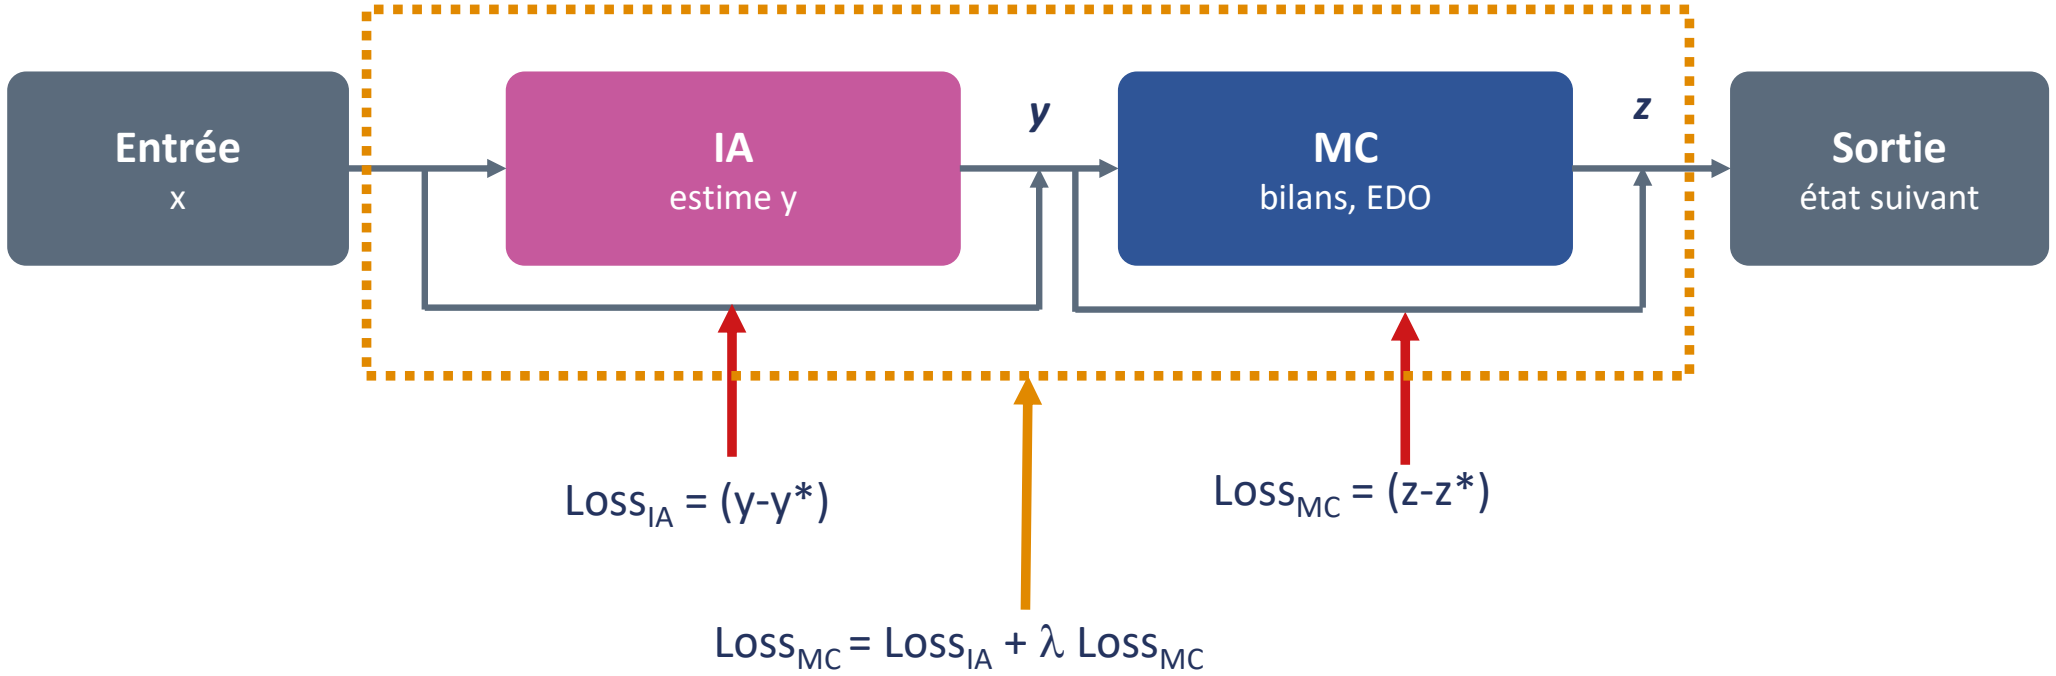
Atout

Le MC existant est conservé tel quel : l'IA ne corrige que l'écart.

Limite

Instabilités numériques.

D · Cas particulier



Modèle Hybride : PINNs

Physics Informed Neural Networks

LABORATOIRE RÉACTIONS ET GÉNIE DES PROCÉDÉS

Avantages et inconvénients

Avantages

1 Moins de données

Le MC contraint le modèle : l'IA apprend peu de choses, donc avec peu de points.

2 Meilleure extrapolation

Au-delà des données, mieux qu'une IA seule. Les conditions de garantie restent à établir.

3 Cohérence physique

Bilans de matière et d'énergie respectés par construction (architecture série IA → MC).

4 Physique manquante révélée

Le terme appris se lit et se compare à la connaissance : mécanismes latents, cinétiques.

Inconvénients

1 Dépendance aux données

Qualité, bruit, perturbations : l'IA reste exposée, surtout aux entrées bruitées.

2 Entraînement plus complexe

Le gradient traverse le MC (EDO, solveur) ; la convergence est difficile.

3 Choix de structure

Que garder, que remplacer ? Décision d'expert, souvent par essais et erreurs.

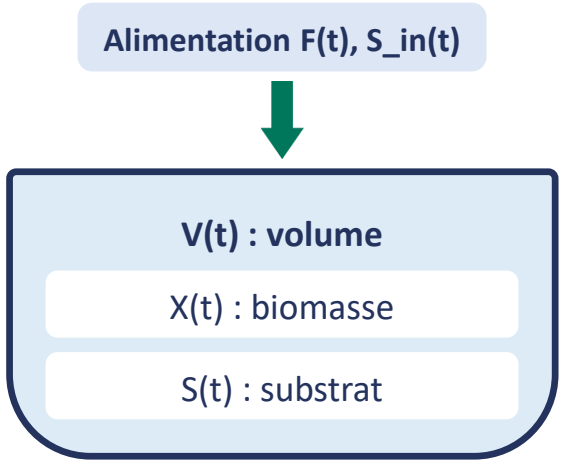
4 Erreurs masquées

Un réseau flexible peut absorber une erreur du MC et rester plausible. Constat issu du tutoriel.

Cas pratique

Fed-batch bioréacteur

Problème étudié - Un bioréacteur à alimentation discontinue



Aucun soutirage : V augmente

Des micro-organismes (**X**) consomment un substrat (**S**) et se multiplient.

On **alimente** la cuve en continu avec un substrat concentré, sans rien retirer : c'est le mode « fed-batch ».

On mesure X et S toutes les **0,2 h**.

Question : comment la croissance dépend-elle de ce qui se passe dans la cuve ?

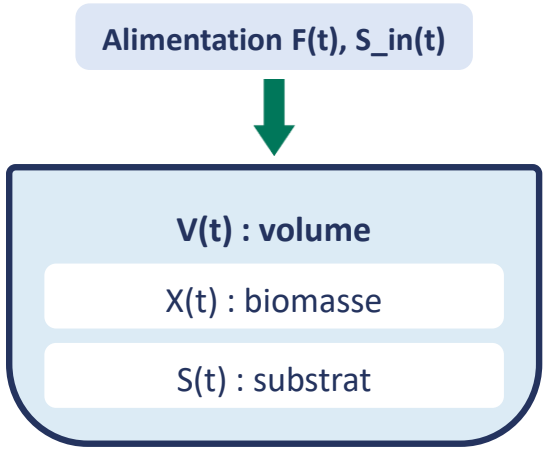
A Hybrid Neural Network-First Principles Approach to Process Modeling

Dimitris C. Psichogios and Lyle H. Ungar
Dept. of Chemical Engineering, University of Pennsylvania, Philadelphia, PA 19104

AIChE Journal **October 1992 Vol. 38, No. 10**

Cas pratique

Problème étudié - Un bioréacteur à alimentation discontinue



Aucun soutirage : V augmente

$$\frac{dX}{dt} = \mu(t) \cdot X(t) - \frac{F(t)}{V(t)} \cdot X(t) \quad (3)$$

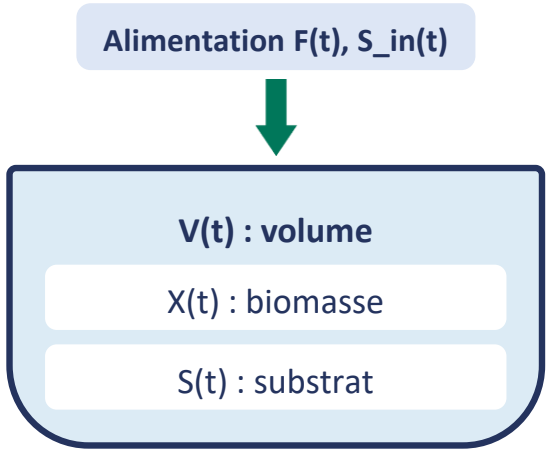
$$\frac{dS}{dt} = -k_1 \cdot \mu(t) \cdot X(t) + \frac{F(t)}{V(t)} \cdot [S_{in}(t) - S(t)] \quad (4)$$

$$\frac{dV}{dt} = F(t) \quad (5)$$

Symbole	Signification	Unité	Statut
X	Concentration en biomasse	g/L	État, mesuré
S	Concentration en substrat	g/L	État, mesuré
V	Volume de la cuve	L	État, **connu** (V_0 = 10 L)
F	Débit d'alimentation	L/h	Commande, **connue**
S_in	Concentration du substrat alimenté	g/L	Entrée, **connue**
k_1	Rendement substrat/biomasse	sans unité	Constante, **connue** (k_1 = 1)
μ	***Vitesse spécifique de croissance***	h^{-1}	***INCONNUE, jamais mesurée***

Cas pratique

Problème étudié - Un bioréacteur à alimentation discontinue



Aucun soutirage : V augmente

$$\frac{dX}{dt} = \mu(t) \cdot X(t) - \frac{F(t)}{V(t)} \cdot X(t) \quad (3)$$

$$\frac{dS}{dt} = -k_1 \cdot \mu(t) \cdot X(t) + \frac{F(t)}{V(t)} \cdot [S_{in}(t) - S(t)] \quad (4)$$

$$\frac{dV}{dt} = F(t) \quad (5)$$

Modèle de Haldane

$$\mu(t) = \frac{\mu^* \cdot S(t)}{K_m + S(t) + \frac{S(t)^2}{K_i}} \quad (6)$$

Symbole	Signification	Unité	Statut
μ*	***Valeur de référence***	h^{-1}	***5***
k_m	Affinité	g/L	10
k_i	Inhibition	g/L	0.1
μ	***Vitesse spécifique de croissance***	h^{-1}	***INCONNUE, jamais mesurée***

Cas pratique

1. « Vrai cinétique – modèle de référence - modèle de Haldane »

Cas pratique

Alimentation F(t), S_in(t)

V(t) : volume

X(t) : biomasse

S(t) : substrat

Aucun soutirage : V augmente

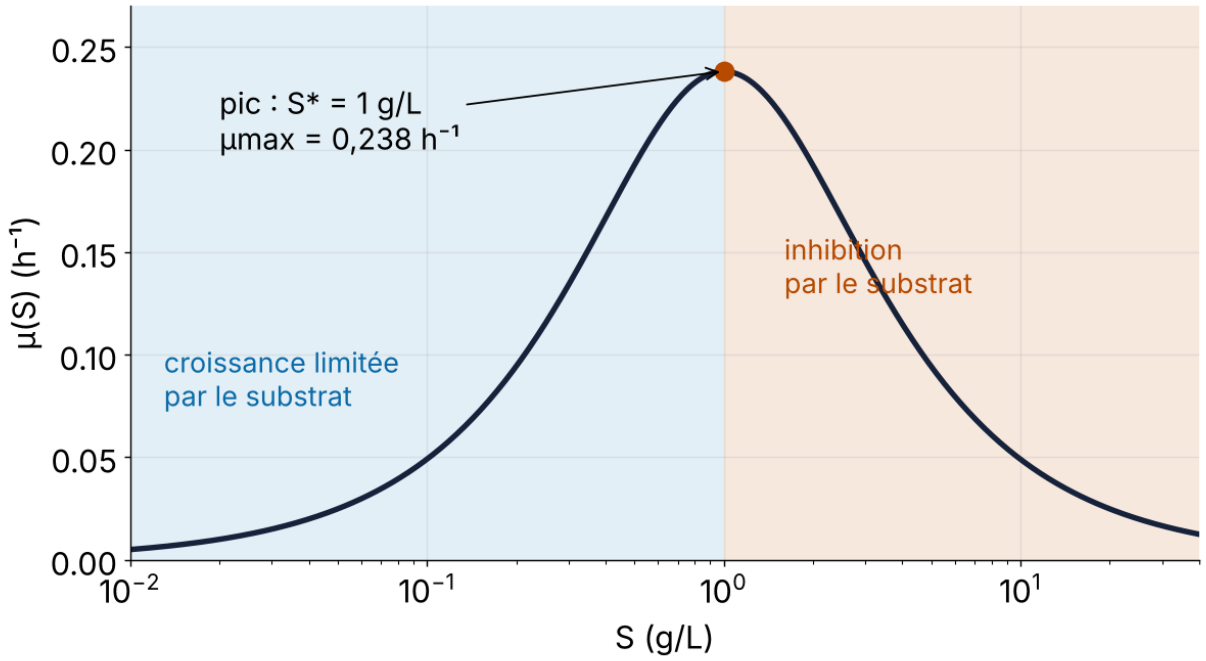
$$\frac{dX}{dt} = \mu(t) \cdot X(t) - \frac{F(t)}{V(t)} \cdot X(t) \quad (3)$$

$$\frac{dS}{dt} = -k_1 \cdot \mu(t) \cdot X(t) + \frac{F(t)}{V(t)} \cdot [S_{in}(t) - S(t)] \quad (4)$$

$$\frac{dV}{dt} = F(t) \quad (5)$$

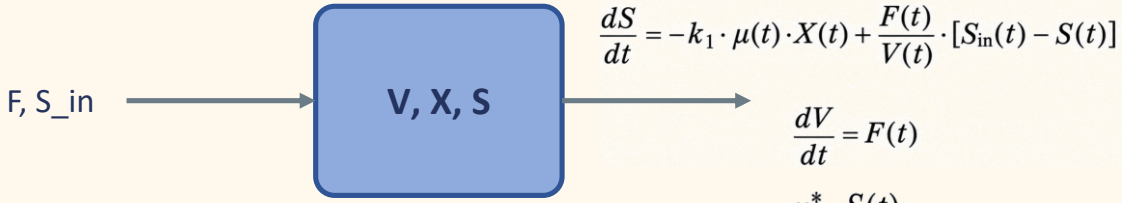
Modèle de Haldane

$$\mu(t) = \frac{\mu^* \cdot S(t)}{K_m + S(t) + \frac{S(t)^2}{K_i}} \quad (6)$$



1. « Vrai cinétique – modèle de référence - modèle de Haldane »

MODÈLE ÉTUDIÉ



$$\frac{dX}{dt} = \mu(t)\cdot X(t) - \frac{F(t)}{V(t)}\cdot X(t)$$

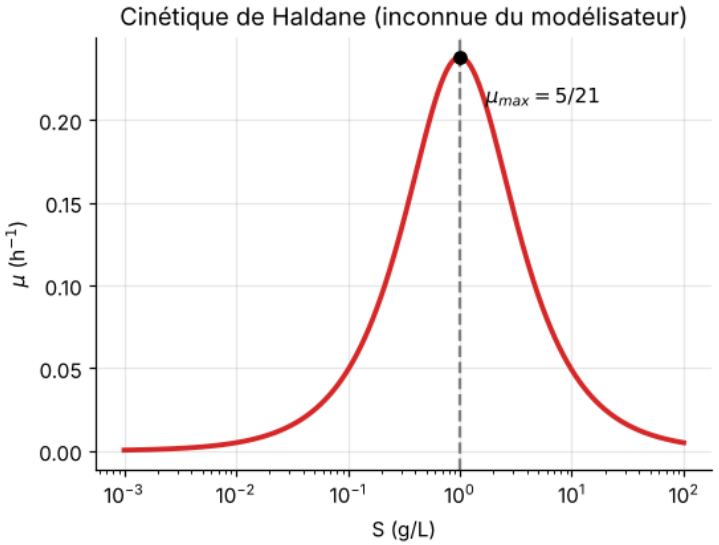
$$\frac{dS}{dt} = -k_1\cdot\mu(t)\cdot X(t) + \frac{F(t)}{V(t)}\cdot[S_{in}(t) - S(t)]$$

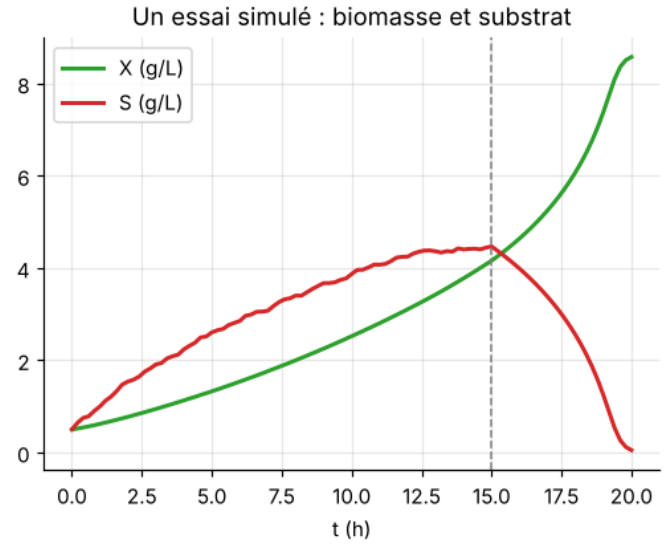
$$\frac{dV}{dt} = F(t)$$

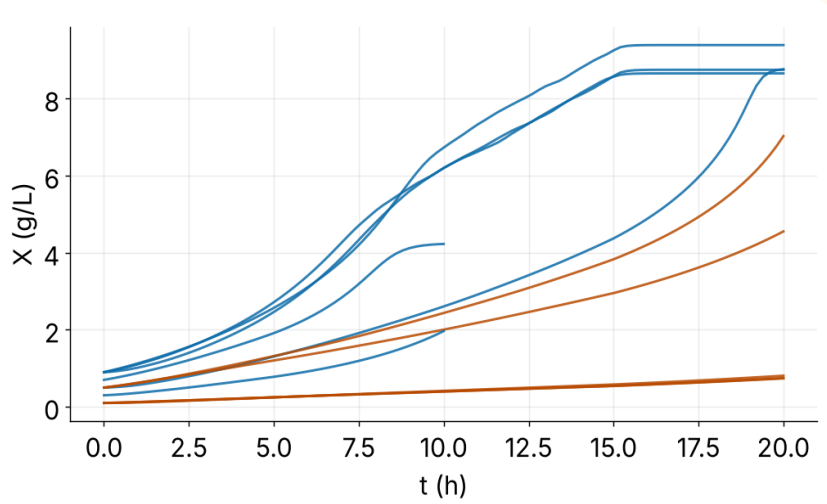
$$\mu(t) = \frac{\mu^*\cdot S(t)}{K_m + S(t) + \frac{S(t)^2}{K_i}}$$

Valeurs choisies pour générer les données

- Débit F : 0,1 L/h, constant pendant l'alimentation
- alimentation de 15h puis F=0 pdt 5h - Δt = 0,2 h
- $(X_o, S_o) \in \{0,1 ; 0,5 ; 0,9\}^2$ - ***Interpolation***
- (X_o, S_o) = (2 ; 0,3), (3 ; 2), (4 ; 1), (5 ; 3) et (6 ; 0,5) g/L - ***Extrapolation***
- Alimentation S_in : 60 g/L ± 50 %, tirage uniforme dans [30 ; 90] g/L







Cas pratique

2 · Pseudo-expériences bruitées

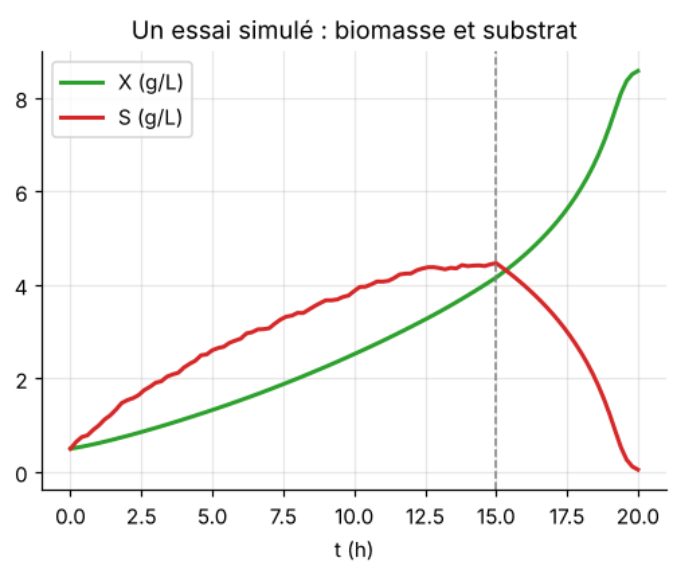
MODÈLE ÉTUDIÉ

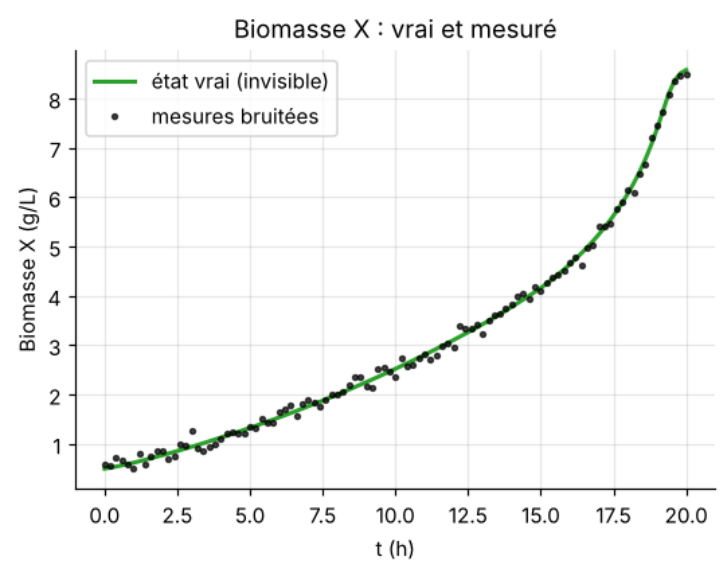
Simulateur (modèle pur) → **+ bruit σ = 0,1 g/L** → **1 000 points (X, S bruités)**

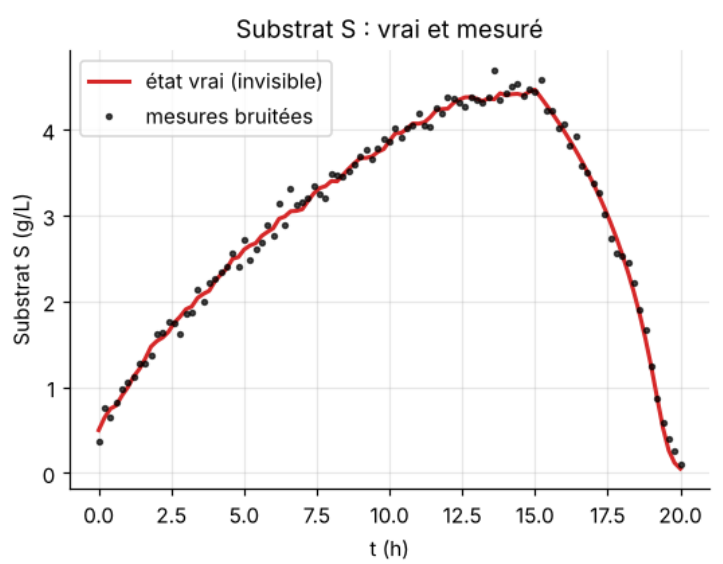
11 essais d'apprentissage · jeux de test : interpolation et extrapolation

Le bruit masque la cinétique

- Bruitage gaussien : σ = 0,1 g/L sur X et S
- V, F et S_in restent exacts
- 1000 points un intervalle de 0,2 h

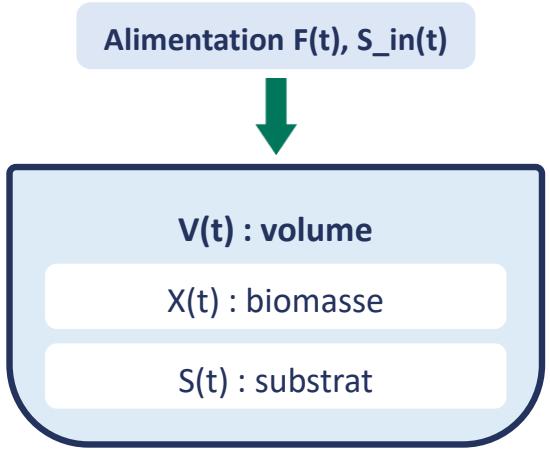






Cas pratique

2bis · Approche simplifiée – Modèle de Monod



Aucun soutirage : V augmente

$$\frac{dX}{dt} = \mu(t) \cdot X(t) - \frac{F(t)}{V(t)} \cdot X(t) \qquad (3)$$

$$\frac{dS}{dt} = -k_1 \cdot \mu(t) \cdot X(t) + \frac{F(t)}{V(t)} \cdot [S_{in}(t) - S(t)] \qquad (4)$$

$$\frac{dV}{dt} = F(t) \qquad (5)$$

Modèle de Monod

$$\mu(S) = \mu_m \frac{S}{K_s + S}$$

μ vitesse spécifique de croissance (h^{-1})

S concentration en substrat (g/L)

Cas pratique

2bis · Approche simplifiée – Modèle de Monod

$$\mu(S) = \mu_m \frac{S}{K_s + S}$$

μ vitesse spécifique de croissance (h^{-1})

S concentration en substrat (g/L)

$$\frac{dX}{dt} = \mu(t) \cdot X(t) - \frac{F(t)}{V(t)} \cdot X(t) \quad (3)$$

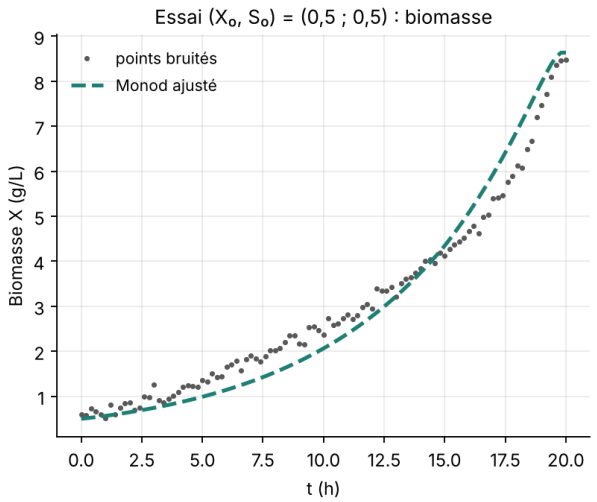
$$\frac{dS}{dt} = -k_1 \cdot \mu(t) \cdot X(t) + \frac{F(t)}{V(t)} \cdot [S_{in}(t) - S(t)] \quad (4)$$

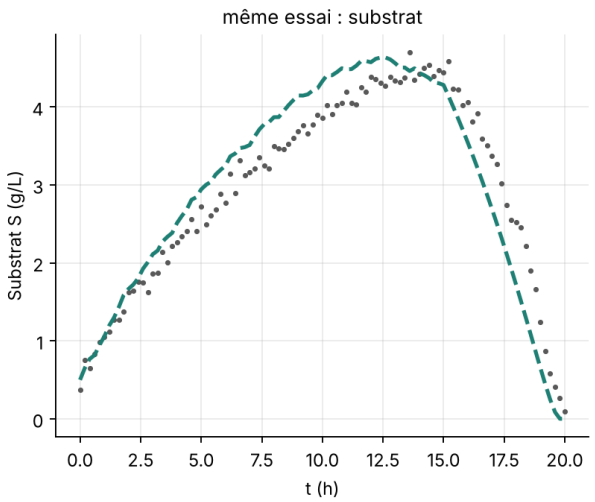
$$\frac{dV}{dt} = F(t) \quad (5)$$

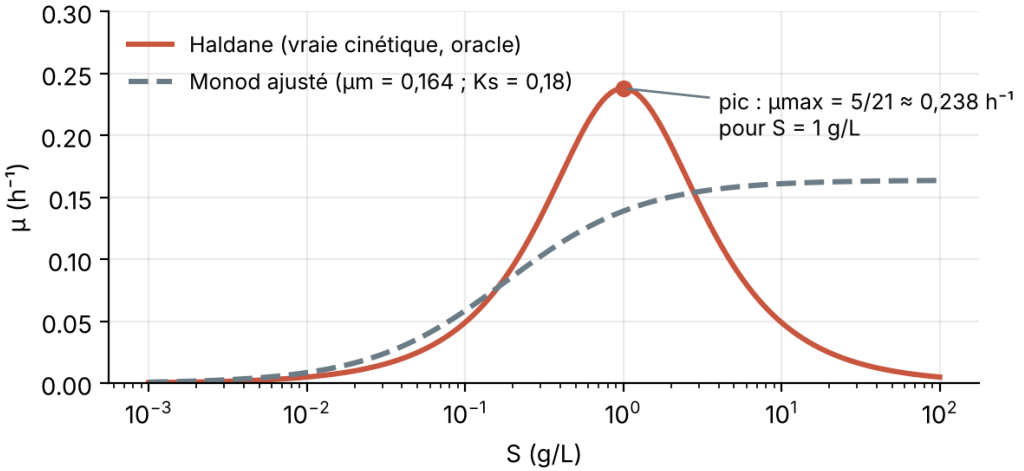
μ_m valeur maximale de µ, le plateau : 0,164 h^{-1} (ajusté)

K_s valeur de S pour laquelle µ = µm/2 : 0,18 g/L (ajusté)

Régression par moindres carrés non linéaires







Cas pratique

Bilan : le cas test, l'oracle et le modèle de Monod

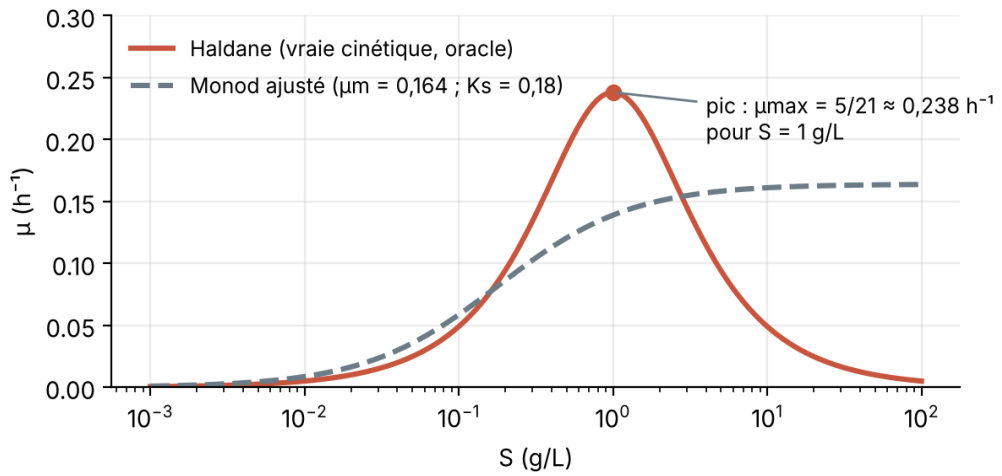
Cas pratique

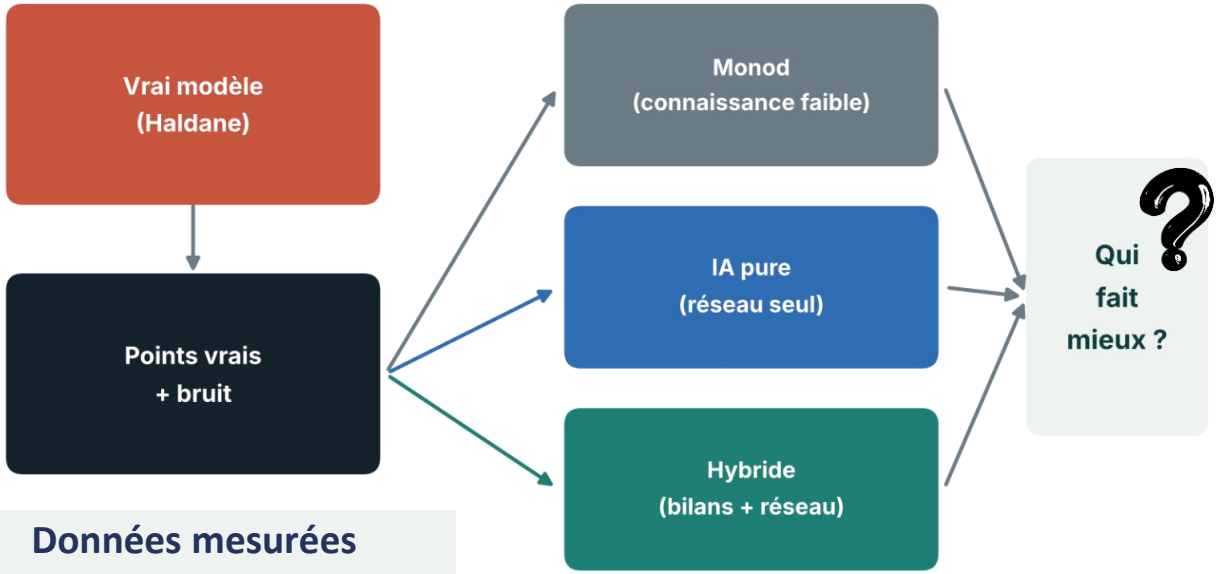
Oracle : bilans + Haldane exact

- $\mu = \mu^* \cdot S / (Km + S + S^2/Ki)$, $\mu^* = 5$, $Km = 10$, $Ki = 0{,}1$
- Pic à S = 1 g/L, $\mu max = 5/21 \approx 0{,}238\ h^{-1}$; inhibition au-delà
- Paramètres connus, rien n'est appris : c'est la vraie physique
- Rôle : meilleur résultat possible, plancher dû au bruit

Monod : bilans + cinétique approchée

- $\mu = \mu m \cdot S / (Ks + S)$: saturante, sans inhibition
- 2 paramètres ajustés par moindres carrés sur les 1 000 points bruités ($\mu m \approx 0{,}164\ h^{-1}$, $Ks \approx 0{,}18$ g/L)
- Connaissance seule : on ignore l'inhibition par le substrat
- Rôle : repère que l'hybride doit battre

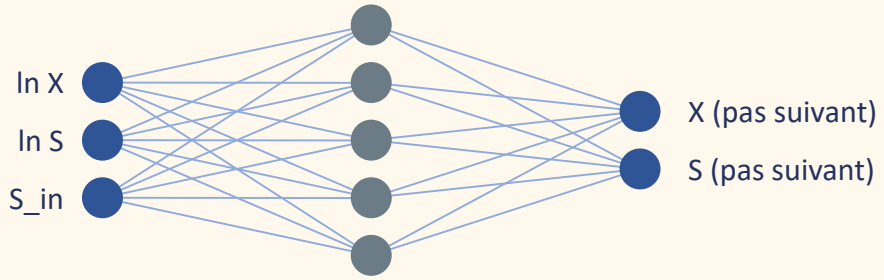




Données mesurées (1000 points)

3 · IA pure : un réseau seul

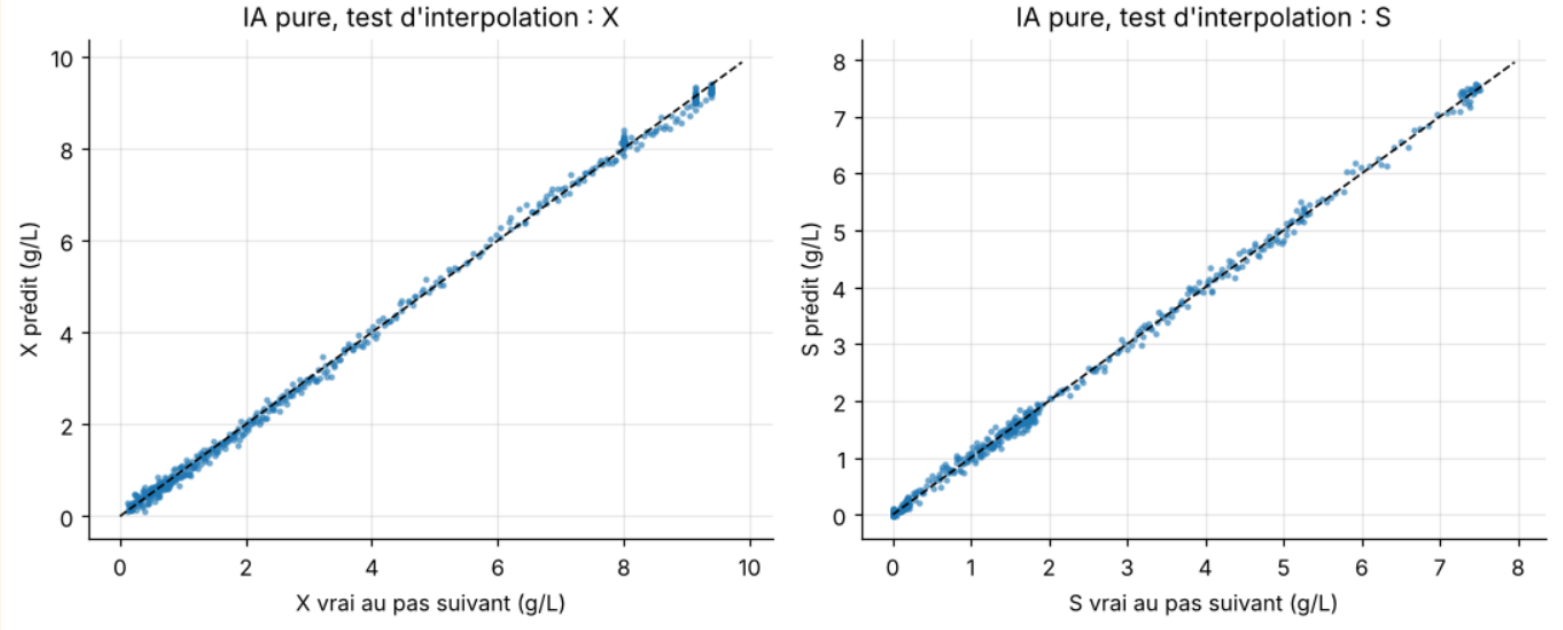
MODÈLE ÉTUDIÉ



3 → 8 → 2 (8 neurones, 5 dessinés) · aucune physique : ni bilans, ni F, ni V

Métriques

MSE à un pas (éq. 10)	interpolation	extrapolation
IA pure	6.21e-06	2.53e-04
Oracle (Haldane vrai)	4.97e-06	4.92e-06

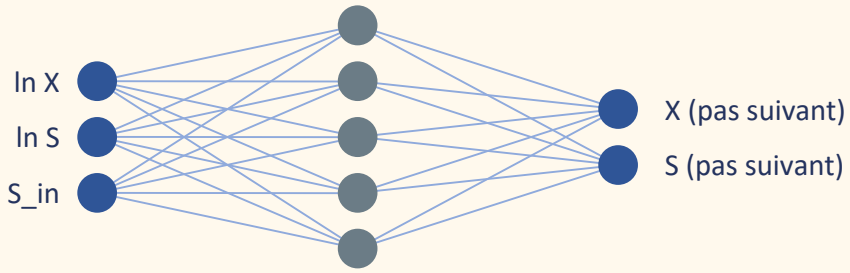


Cas pratique

3 · IA pure : un réseau seul

Résultats mitigés pour le sens physique

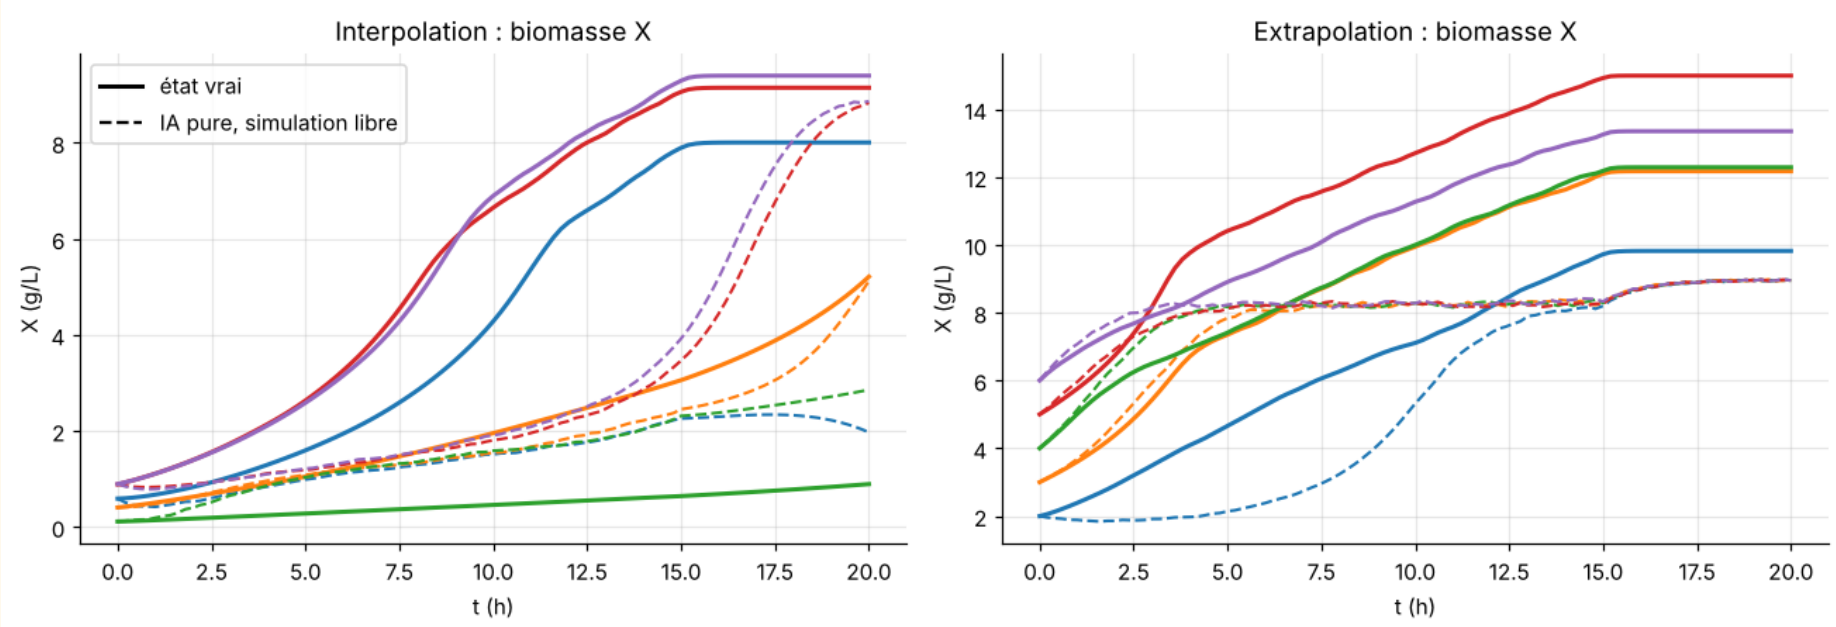
MODÈLE ÉTUDIÉ



3 → 8 → 2 (8 neurones, 5 dessinés) · aucune physique : ni bilans, ni F, ni V

Métriques

	RMSE X libre interp	RMSE X libre extrap
IA pure	2.87	2.99
Oracle	0.04	0.03



Cas pratique

4 · Hybride série : réseau dans les bilans



Hybride série (modèle B) : construction, entrées / sorties de chaque bloc et critère d'apprentissage

DONNÉES
(un intervalle k)

mesurés (bruités) : X(k), S(k) et cibles X(k+1), S(k+1) exacts, connus : V(k), F(k), S_in(k), Δt = 0,2 h, k_1 = 1

1 000 intervalles · 700 pour ajuster les poids · 300 pour la validation (arrêt précoce)

X, S mesurés

V, F, S_in exacts

cibles k+1

① Entrées du réseau

ln X(k)
ln S(k)

2 valeurs (échelle log)

② Réseau de neurones

2 → 8 → 1

8 neurones cachés (tanh)
sortie s ∈]0 ; 1[, puis μ = 2·μmax·s
(μ positif et borné)
33 paramètres à ajuster

③ Bilans de matière (analytiques)

entrées : μ, X(k), S(k), V(k), F(k), S_in(k)

$V_1 = V + F \cdot \Delta t$
$\hat{X}(k+1) = X \cdot \exp(\mu \Delta t) \cdot V / V_1$
$\hat{S}(k+1) = [S \cdot V + F \cdot S_{in} \cdot \Delta t - k_1 \cdot X \cdot V \cdot (\exp(\mu \Delta t) - 1)] / V_1$

aucun paramètre appris · matière conservée

④ Critère (loss)

J = moyenne sur les intervalles de

$[(\hat{X} - X)^2 + (\hat{S} - S)^2] / 60^2$

$\hat{X}$, $\hat{S}$ prédits · X, S mesurés à k+1 · même poids X et S

Rétropropagation : le gradient de J traverse les bilans puis corrige les poids du réseau

Ce que le réseau voit

Il n'a aucune cible pour μ : μ n'est jamais mesuré.
Il est entraîné de façon indirecte, par l'erreur sur l'état suivant calculé par les bilans.

Apprentissage

Adam (pas 0,02) · lots complets · jusqu'à 30 000 époques
arrêt précoce sur la perte de validation (300 points)
meilleur résultat obtenu à l'époque 160

Cas pratique

4 · Hybride série : réseau dans les bilans

Cas pratique

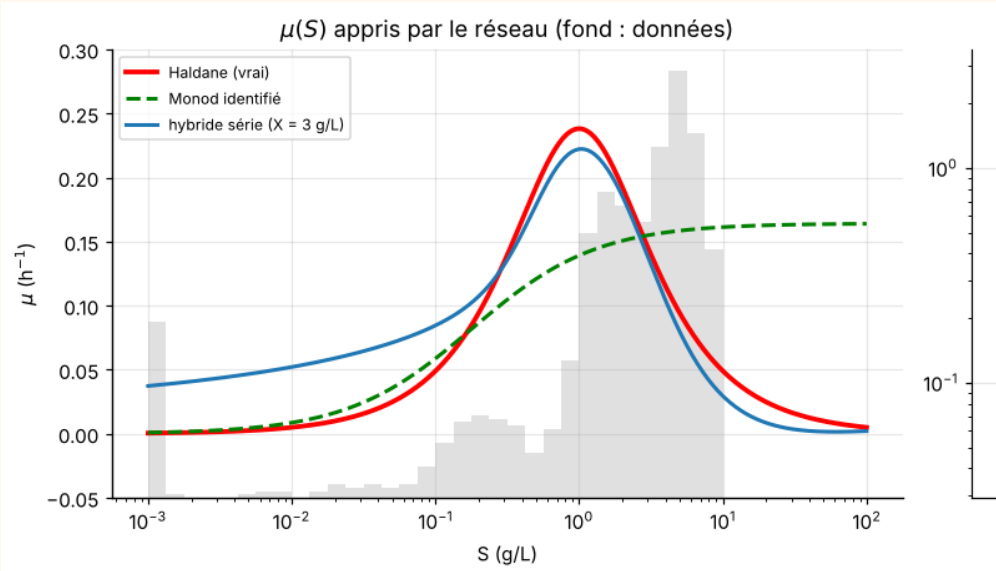
MODÈLE ÉTUDIÉ

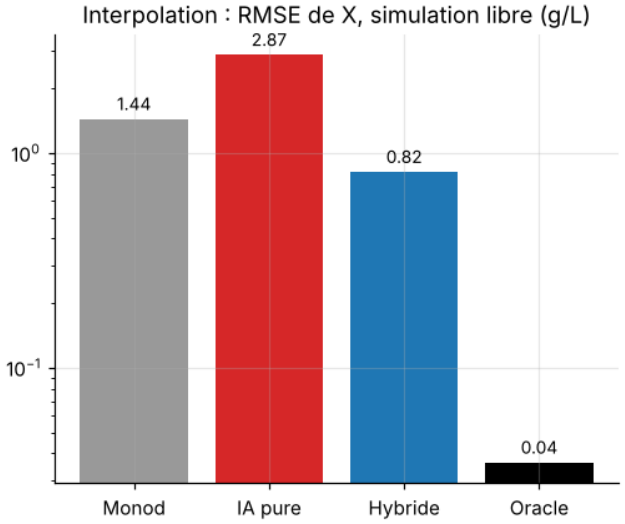


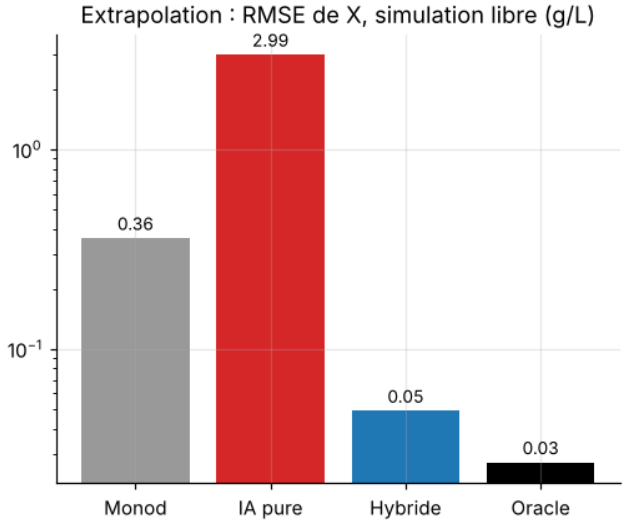
entrées : X, S courants ; F, V, S_in connus (2 → 8 → 1, sortie μ)

Le réseau n'apprend que μ(S)

- Erreur 0,82 / 0,05 g/L (interp. / extrap.) contre 2,87 / 2,99 pour l'IA pure
- 160 époques au lieu de 11 570
- Matière conservée : dérive de 10^{-13} g







5 · Influence de la taille du jeu de données

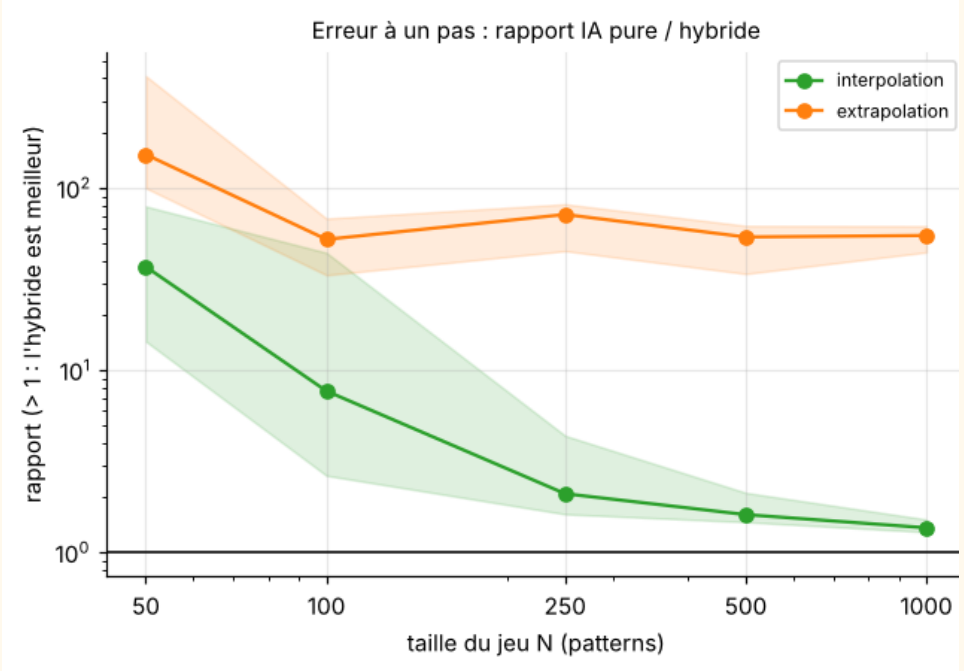
MODÈLE ÉTUDIÉ



10 sessions par taille · erreur à un pas et en simulation libre

L'avantage dépend du critère

- À un pas : de ×37 (N = 50) à ×1,4 (N = 1 000)
- En simulation libre, extrapolation : de ×6,5 à ×37
- L'IA pure rattrape à un pas



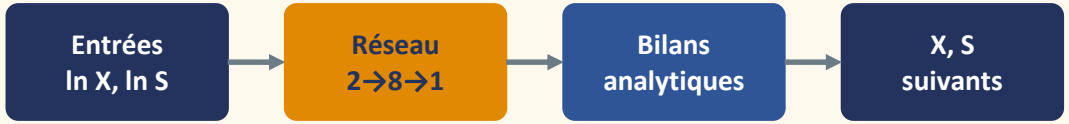
Plus le nombre de data augmente plus l'approche IA pure se rapproche de l'approche hybride

Cas pratique

6 · Influence de l'architecture

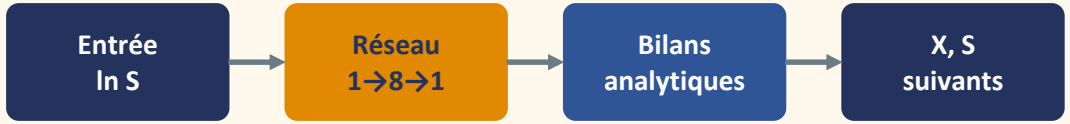
B · série réseau → physique

= modèle de la partie 4



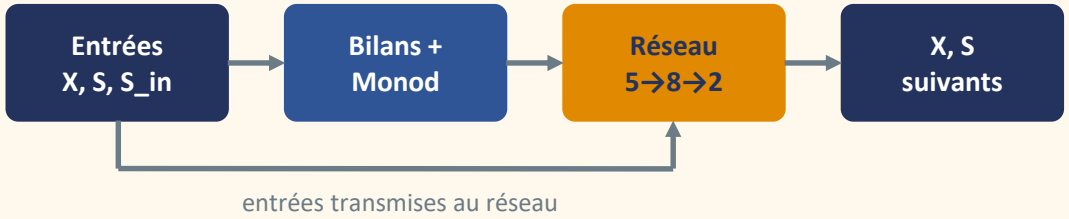
Le réseau fournit μ ; les bilans calculent X et S. RMSE X : 0,84 / 0,08 g/L. Matière conservée.

B' · variante de B, entrée S seule



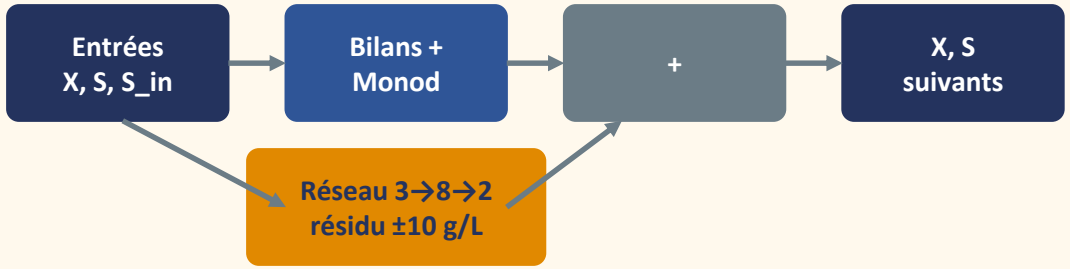
μ ne dépend que de S : on restreint l'entrée. RMSE X : 0,51 / 0,07 g/L, la meilleure. Matière conservée.

A · série physique → réseau



Entrées du réseau : ln X, ln S, S_in/60 et la prédiction de Monod (ln X̃, ln S̃). RMSE X : 1,97 / 3,00 g/L. Dérive de matière : 79 g.

C · parallèle (résidu)



Le résidu (±10 g/L, entrées ln X, ln S, S_in/60) s'ajoute à la prédiction de Monod. RMSE X : 1,29 / 0,95 g/L. Dérive de matière : 33 g.

Cas pratique

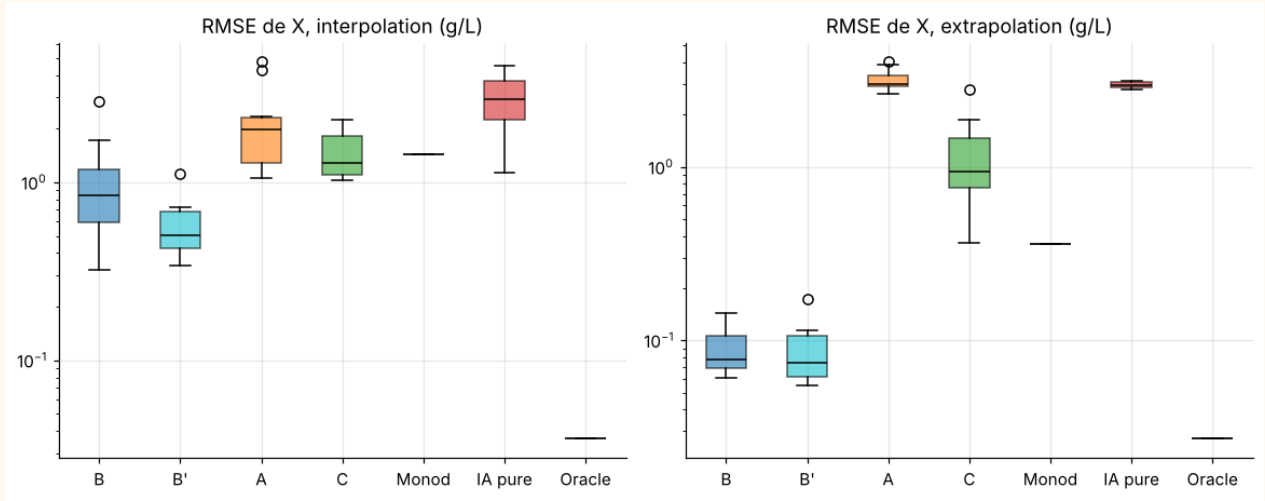
6 · Influence de l'architecture

MODÈLE ÉTUDIÉ

A — **Physique** → **Réseau** : série physique → réseau

B — **Réseau μ** → **Physique** : série réseau → physique

C — **Physique** + **Réseau (résidu)** : + parallèle : sorties additionnées



Placer le réseau dans la physique

1.Mettre le réseau à l'intérieur de la physique. Dans B, le réseau ne remplace que la fonction inconnue μ, et les bilans restent exacts. Dans A et C, le réseau corrige les sorties et peut donc violer la conservation de la matière

2.Un hybride mal conçu peut faire pire que sa propre physique. En extrapolation, C donne 0,95 g/L contre 0,36 pour Monod seul, et A est presque aussi mauvais que l'IA pure.

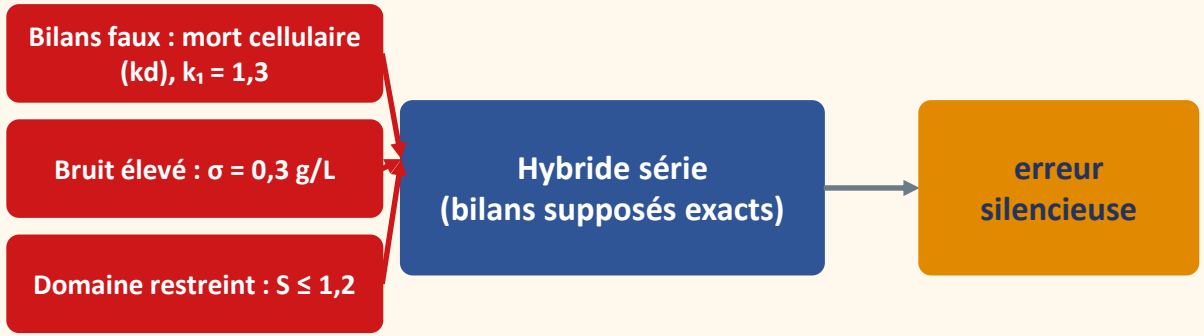
3.Réduire le réseau à ce qu'on ne sait pas. B', où μ dépend de S seulement, améliore encore l'interpolation de 40 % par rapport à B. Injecter de la connaissance dans l'architecture vaut des données.

4.La conservation de la matière est une propriété de l'architecture, pas quelque chose que le réseau apprend.

Cas pratique

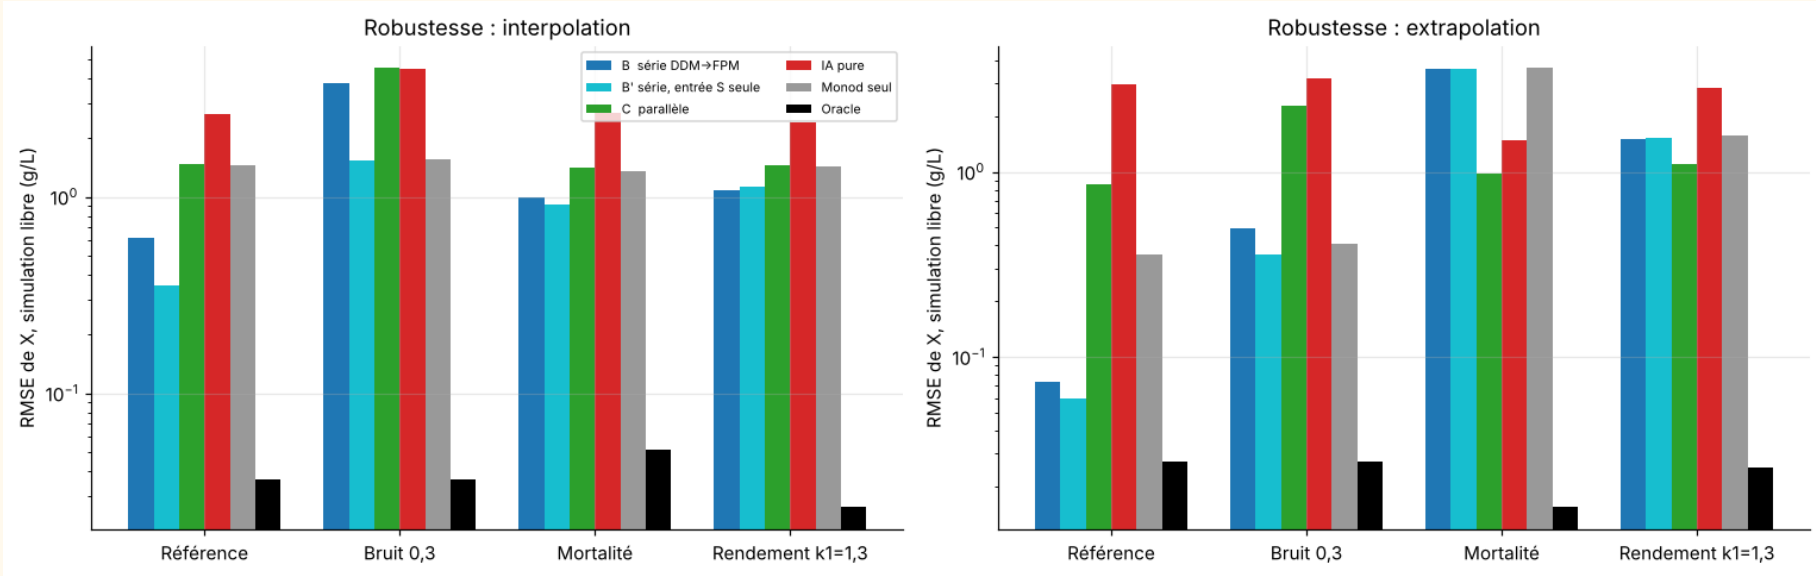
7 · Risques et limites des modèles hybrides

MODÈLE ÉTUDIÉ



Un avantage conditionnel

- Bilans faux : erreur ×20 à ×60, invisible à un pas
- Bruit de 0,3 g/L : hybride ≈ Monod seul (1,53 contre 1,54)
- Hors domaine appris : le réseau ne devine pas l'inhibition

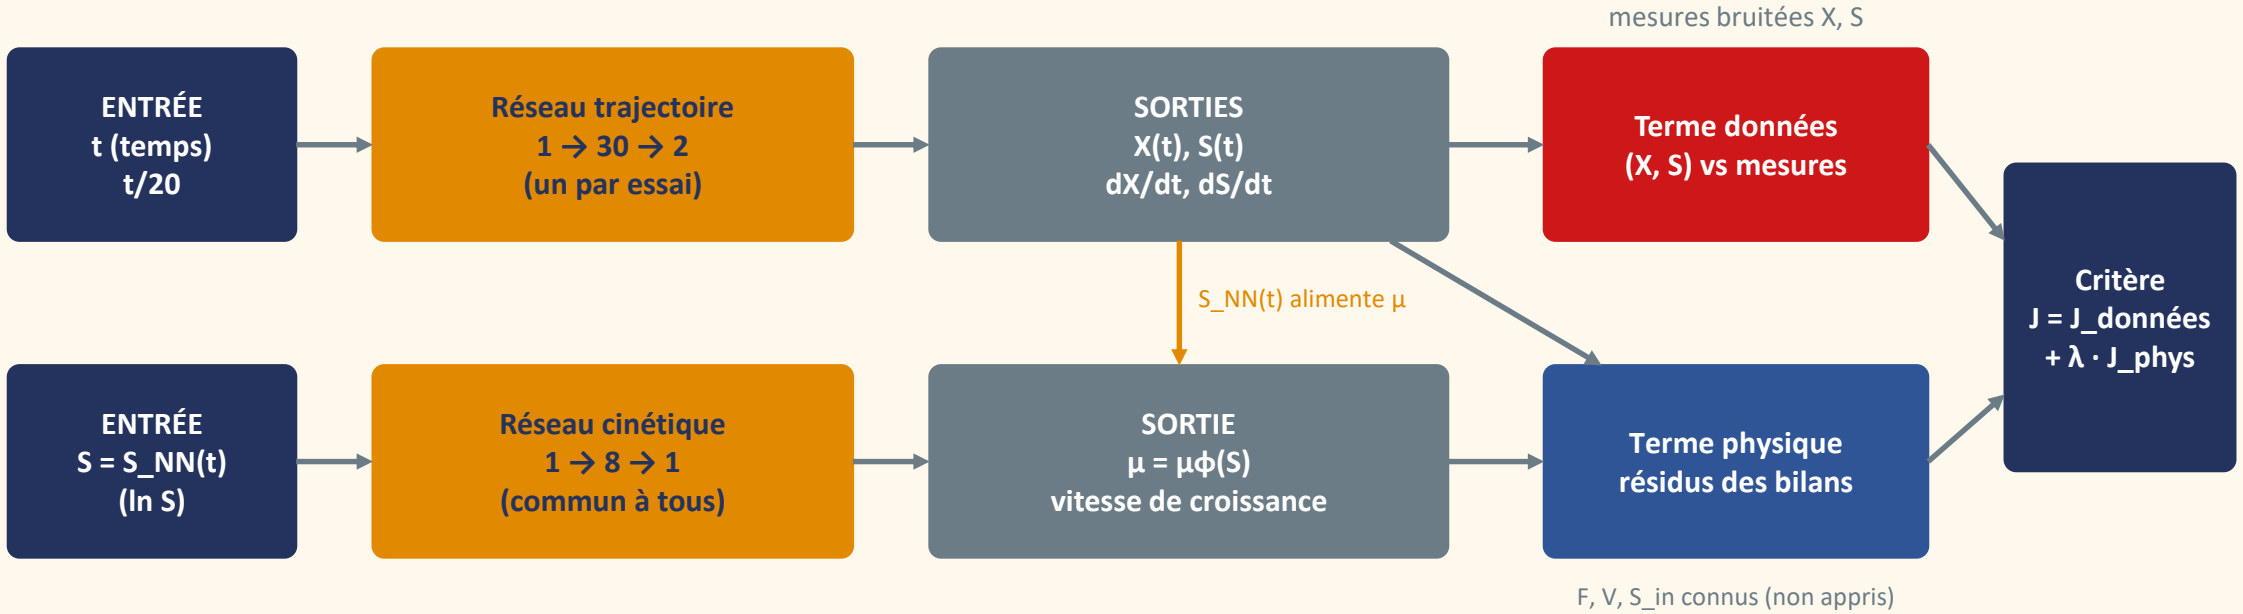


Un hybride n'est utile que si la structure physique est fiable, si l'inconnu est localisé et si les données couvrent le domaine d'usage.

Cas pratique

8 · PINN : deux réseaux, leurs entrées et sorties

MODÈLE ÉTUDIÉ



résidus : $r_X = dX/dt - (\mu - F/V)\cdot X$ $\quad r_S = dS/dt + k_1\cdot\mu\cdot X - (F/V)\cdot(S_{in} - S)$

bilans : $dX/dt = (\mu - F/V)\cdot X$; $dS/dt = -k_1\cdot\mu\cdot X + (F/V)(S_{in} - S)$

Qui voit quoi ?

Seul le réseau trajectoire voit les mesures, par le temps. Le réseau cinétique ne voit jamais de μ mesuré : il est contraint par la physique seule.

Après l'entraînement

On ne garde que μϕ(S). On le branche dans les bilans de la partie 4 : mêmes tests et mêmes repères que les parties 3 à 7.

Réglages fixés une fois

σ = 0,1 g/L (données), ρ = 0,05 g/L/h (physique), 4 points de collocation par intervalle de 0,2 h, λ de 0 à 1.

Cas pratique

8 · PINN : calcul de la physique et du gradient

1 · Réseau et dérivées analytiques

$h = \tanh(W1 \cdot t/20 + b1)$; $N = W2^{T} h + b2$; $X = 10 \cdot N_1$, $S = 5 \cdot N_2$

$dN/dt = (1/20) \cdot \Sigma\ W2 \cdot (1 - h^2) \cdot W1$: dérivée exacte du réseau, sans différences finies.

2 · Résidus des bilans en 4 points par intervalle

$\mu = \mu\phi(S_NN)$; $D = F/V$, $V = V_k + F \cdot (t - t_k)$

$r_X = dX/dt - (\mu - D) \cdot X$

$r_S = dS/dt + k_1 \cdot \mu \cdot X - D \cdot (S_in - S)$

Aucune intégration pendant l'entraînement : les bilans ne sont qu'une pénalité.

3 · Critère

$J = J_d + \lambda \cdot J_p$

$J_d = \text{moy}[(X - X_m)^2 + (S - S_m)^2] / \sigma^2$

$J_p = \text{moy}[r_X^2 + r_S^2] / \rho^2$

Les normalisations σ^2 et ρ^2 rendent les deux termes comparables.

4 · Gradient écrit à la main

$g_\mu = -X \cdot g_X + k_1 X \cdot g_S$ (sensibilité de J à μ, vers le réseau cinétique)

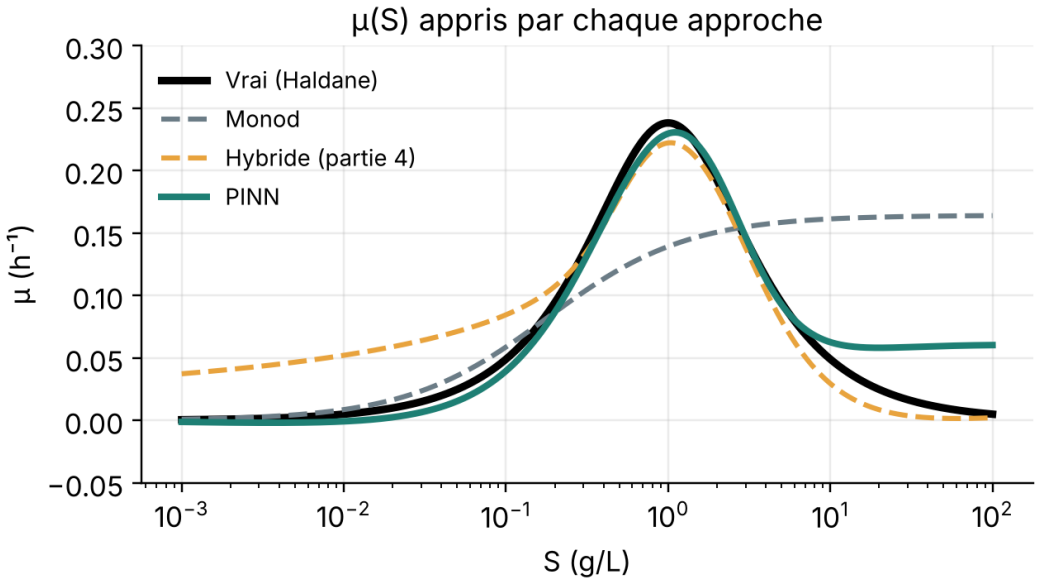
$g_S,dir = D \cdot g_S + g_\mu \cdot d\mu/dS$: μ dépend de S, donc de la trajectoire

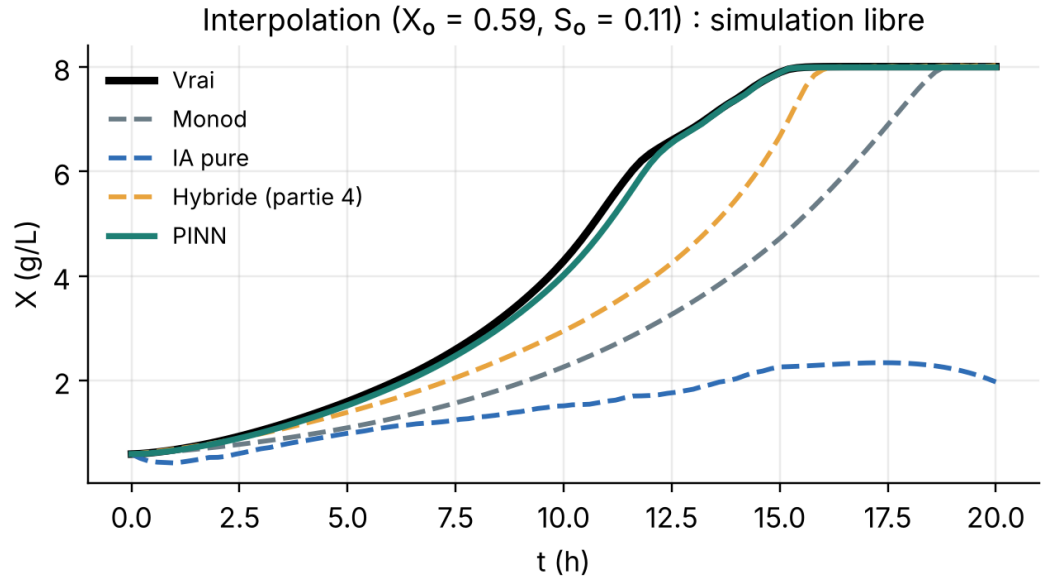
Deux chemins vers les poids du réseau 1 : la valeur N et sa dérivée dN/dt (dérivée seconde). Vérifié à 10^{-8}.

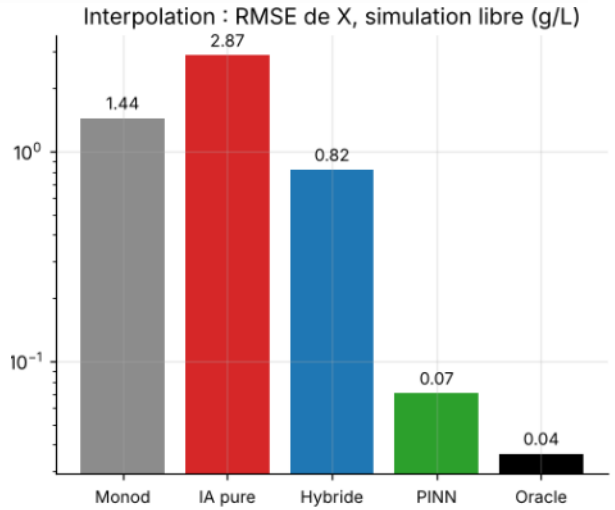
Entraînement : L-BFGS-B, λ = 0 → 0,01 → 0,1 → 1 (3000 itérations par palier). Évaluation : on garde μϕ(S) et on simule librement 20 h dans les bilans.

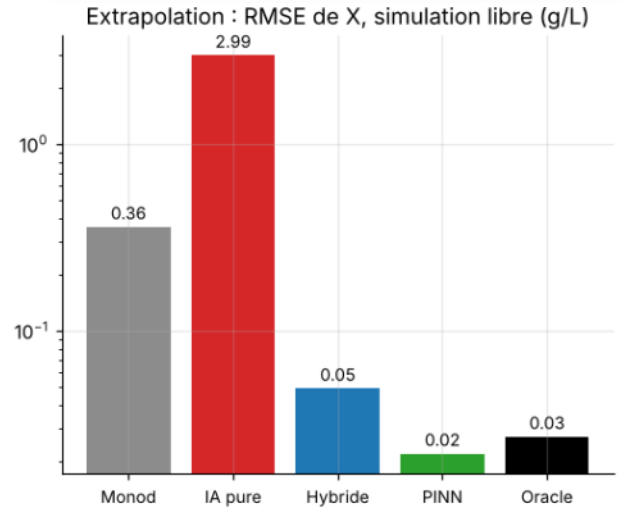
Cas pratique

8 · PINN : résultats et limites









Cas pratique

8 · PINN : résultats et limites

0,07 à 0,20 g/L

interpolation, 5 initialisations du PINN (hybride de la partie 4 : 0,82 ; Monod : 1,44)

0,02 à 1,12 g/L

extrapolation selon l'initialisation, médiane 0,58 (Monod : 0,36 ; hybride : 0,05)

1,69 contre 4,07

bruit de 0,3 g/L, interpolation : PINN contre hybride ; Monod seul fait 1,54

1.Il n'est pas plus robuste en extrapolation : de 0,02 à 1,12 g/L selon l'initialisation (médiane 0,58). La physique dans le critère n'est pas la physique dans la structure : ce qu'il apprend mal reste mal contraint.

2.Il coûte plus cher : environ 1 400 paramètres, une minute d'entraînement (contre quelques secondes pour l'hybride série), des séries temporelles complètes, F(t) et S_in(t) connus à tout instant, un gradient du second ordre écrit à la main.

3.Plus difficile mathématiquement à mettre en place : modèle mathématique complexe et optimiser λ dans la loss devient un hyperparamètre à optimiser

Au-delà de l'exemple : risques et limites des modèles hybrides

Cas pratique

1 · Le réseau hérite des erreurs de la physique

Ici : un terme de mort cellulaire absent des bilans, ou un rendement faux, multiplie l'erreur par 20 à 60 en extrapolation.

En général : toute hypothèse physique fausse est transmise, avec d'autant plus de confiance que la structure est rigide. Une validation à un pas ne la voit pas.

2 · Le réseau ne connaît que son domaine

Ici : appris sur $S \leq 1{,}2$ g/L, le réseau ne devine pas l'inhibition au-delà.

En général : l'hybride extrapole bien ce que la physique couvre, pas ce qui manque aux données. Hors plage, la fonction apprise n'est pas garantie.

3 · Peu de données ou trop de bruit : pas de gain

Ici : à $N = 100$ ou $\sigma = 0{,}3$ g/L, l'hybride fait jeu égal avec Monod seul.

En général : il faut assez de données de qualité pour que le réseau fasse mieux que la connaissance seule. Sinon la complexité ajoutée est inutile.

4 · Un bon score de validation ne suffit pas

Ici : l'erreur à un pas est au niveau du bruit pour presque tous les modèles, même ceux qui échouent sur 20 h.

En général : valider en simulation libre, hors plage, avec le bilan de matière, et toujours contre la connaissance seule.

L'hybride vaut le coup quand la structure physique est fiable, que l'inconnu est localisé (une fonction, un paramètre) et que les données couvrent le domaine d'usage.

Ressources sur GitHub

Cas pratique

Toutes les ressources présentées sont disponibles sur mon compte GitHub

https://github.com/bounac80/Modele_Hybride

Scanner pour accéder au dépôt

LABORATOIRE
RÉACTIONS
ET GÉNIE
DES PROCÉDÉS

Merci

pour votre attention

Retrouvez notre actualité scientifique sur notre site web et que sur notre page LinkedIn